

APLICAÇÃO DO DEEP LEARNING EM ANÁLISE DE DIAGNÓSTICO POR IMAGENS

APPLICATION OF DEEP LEARNING IN DIAGNOSTIC IMAGE ANALYSIS

Cauê Nunes Moreira¹

Emanoel da Costa Oliveira¹

Gabriel Cazarim Pieper¹

Gabriel Gustavo Silva Costa¹

José Henrique¹

RESUMO

Através do tempo, as técnicas de medicina evoluíram assim como a tecnologia a ela correlata, sendo descobertas novas maneiras de diagnosticar doenças, realizar exames e procedimentos. O presente artigo visa apresentar resultados de um estudo de caso utilizando o Deep Learning aplicado à medicina com foco em análise de imagens de raio-x para diagnóstico de doenças pulmonares. Além disso, visa também exemplificar como este recurso pode beneficiar, apoiar e ajudar os profissionais da medicina nestes diagnósticos. Como metodologia, utilizou-se pesquisa bibliográfica para obtenção de dados e informações sobre o assunto, além do estudo de caso utilizando um algoritmo de regressão logística binomial de *Deep Learning*. A partir do estudo de caso, os resultados obtidos apontam para o benefício da utilização da tecnologia para auxílio no diagnóstico de imagens de raio-x para doenças pulmonares. Salienta-se que a tecnologia pode ser aplicada para outros tipos de diagnósticos por imagens e também como banco de dados para pesquisas futuras de médicos pesquisadores.

Palavras-chave: Medicina; *Machine Learning*, *Deep Learning*; Algoritmo.

ABSTRACT

Through time, as medical techniques evolved, as did the technology associated with it, and new ways of diagnosing illnesses, performing exams, and procedures were discovered. This

¹ Faculdade Impacta de Tecnologia - São Paulo, SP, Brasil - Curso Bacharelado em Sistema de Informação
article aims to present the results of an experiment using Deep Learning applied to medicine with a focus on x-ray image analysis for the diagnosis of lung diseases. In addition, it also aims to exemplify how this resource can benefit, support and help medical diagnosticians. As a methodology, bibliographic research was used to obtain data and information on the subject, in addition to the experimentation of an algorithm using Deep Learning. From the experimentation, the results obtained point to the benefit of using the technology to aid in the diagnosis of x-ray images for lung diseases. It should be noted that the technology can be applied to other types of diagnostic imaging and also as a database for future research by researchers.

Keywords: Medicine, Machine Learning, Deep Learning, Algorithm.

1 INTRODUÇÃO

Há cerca de 20 anos atrás, não conseguiríamos imaginar a internet como ela é hoje, até mesmo pensar no funcionamento de uma rede 4G conectado aos celulares ou automóveis guiados de forma autônoma. O que esperar das tecnologias de *Deep Learning* para o futuro? *Deep Learning* ou aprendizagem profunda em tradução livre, consiste em uma rede neural dotada de três ou mais camadas, no intuito de simular o comportamento de um cérebro humano.

Esta tecnologia possibilita que a máquina assimile mais profundamente que uma inteligência artificial (IA) tradicional. Tais modelos podem adquirir complexidade e precisão excedentes ao nível humano, sendo utilizadas em diversos ramos de atividades de forma disruptiva.

Os algoritmos de *Deep Learning* são capazes de realizar tarefas como reconhecimento de fala, identificação de imagens e realizar projeções. Para tanto são determinados padrões básicos das informações de forma organizá-las, possibilitando a “aprendizagem” dos computadores com base nas camadas de processamento que identificam os padrões determinados.

Desta forma, entende-se que o *Deep Learning* é constituído por um conjunto de algoritmos de *Machine Learning* com capacidade de integração em vários níveis, expressos por modelos estatísticos reconhecidos e abrangentes.

Conforme o autor:

“Recentemente, foram desenvolvidas novas técnicas a partir de Deep Learning, as quais têm impactado em diversos estudos sobre processamento de sinais e identificação de padrões.” (CHAGAS, Edgar Thiago De Oliveira, 2019, p.2)

Ainda conforme o mesmo autor:

“O Deep Learning abrange a aprendizagem em diversos níveis de representação e intangibilidade que auxiliam no processo de compreensão das informações, das imagens, dos sons e dos textos.” (CHAGAS, Edgar Thiago De Oliveira, 2019, p.2)

O *Deep Learning* atrelado ao *Machine Learning* tem alavancado a eficiência e eficácia dos conceitos e métodos de identificação, estudos e processos dentro da medicina em geral. Os Recursos Computacionais envolvendo as técnicas de visão Computacional são utilizados no auxílio do diagnóstico de imagens.

De acordo com Gonçalves (2010, apud Mendes, Yana, p.2, 2020), essas técnicas tem como objetivo construir sistemas para interpretar imagens, através da transformação de uma imagem em uma estrutura de dados simplificada.

Com algoritmos de aprendizagem de máquina as imagens podem ser amplamente analisadas e classificadas de forma a potencializar a assertividade no apoio dos diagnósticos, diminuindo drasticamente a quantidade de imagens solicitadas, impactando fortemente em custos e insumos.

O presente trabalho consiste na aplicação de um algoritmo de *Deep Learning*, que visa possibilitar a leitura de imagens de raio-x de forma a classificá-las entre pacientes saudáveis e doentes.

1.1 METODOLOGIA

Para a realização do presente artigo foi utilizada a metodologia de pesquisa bibliográfica iniciando-se por meio de uma revisão da literatura relacionada a *Deep Learning*

e *Machine Learning* voltadas a medicina no âmbito de imagens em obras já existentes e consolidadas, com o objetivo de apoiar este estudo no desenvolvimento do tema proposto.

Utilizamos como pesquisa bibliográfica a Revista The Lancet, pois é um periódico semanal onde é abordado assuntos direcionados a medicina, além de ser uma das mais antigas e relevantes revistas médicas do mundo. Através do site <https://www.thelancet.com>.

Utilizamos o ícone de busca para encontrar artigos relacionadas a deep learning, sendo selecionado o artigo base para estudo: “A comparison of deep learning performance Against health-care professionals in me diseases from medical” (em tradução livre “Uma comparação do desempenho de aprendizagem profunda com profissionais de saúde na detecção de doenças por imagens médicas: uma revisão sistemática e meta-análise”) publicado na revista científica The Lancet em 25/09/2019 ([https://doi.org/10.1016/S2589-7500\(19\)30123-2](https://doi.org/10.1016/S2589-7500(19)30123-2)).

Realizou-se também um estudo de caso com o objetivo de classificar imagens de raio-x para diagnóstico de doenças pulmonares, com o desenvolvimento de um modelo a partir de algoritmo de regressão logística binomial, para treinamento, validação e teste, com o intuito de contribuir e apoiar a tecnologia aplicada à medicina. Para a obtenção dos dados de imagens foi utilizado a plataforma *Kaggle* com o título “*Chest X-Ray Images (Pneumonia)*”, contendo um tamanho de 1.24GB.

Utilizou-se a plataforma *Kaggle* para uso do banco de dados de imagens (*chest-xray-pneumonia*), onde foi criada uma chave Api token, que é disponibilizada em formato *Json*. Apoiado no Google *Colab*, o programa é executado, sendo utilizado o Python como linguagem de programação.

Para o desenvolvimento do programa foi necessário o download do *Dataset* na plataforma *Kaggle* e upload do arquivo *kaggle.json* munida das chaves de acesso para a plataforma *Google Colab*. As bibliotecas baixadas e utilizadas foram *Matplotlib*, *Numpy*, *Keras*, *Opencv*, *Zipfile* e *OS*.

Após realizado o *download* dos arquivos citados, e do *dataset* do *Kaggle* foi necessária a configuração do ambiente e suas variáveis, para o recebimento deste *dataset*. Para a utilização do *dataset*, é acionada a biblioteca *zipfile* para interagir com os arquivos compactados, realizando assim a extração dos arquivos.

Para a modelagem utilizou-se o modelo sequencial de forma linear, determinando as camadas. A primeira camada do modelo sequencial envolve convolução 2d, apoiada pela

biblioteca *Keras Layers*, constituindo um processo de treino através de 32 filtros, determinando a leitura da imagem. A função de Kernel mapeia de forma subentendida os dados de seu espaço original para um espaço de recurso de dimensão superior, utilizou-se a dimensão 3x3 para este estudo. Realizou-se também o redimensionamento da imagem através do parâmetro *input sheet*.

Utilizou-se a função ReLU (*rectified linear unit*) para simplificação dos dados onde retorna 0 para todos os valores negativos, e o próprio valor para valores positivos. Fez-se o uso do processo de *Max-pooling* na camada, onde apenas o maior número da unidade é passado para a saída. Nesse caso, ocorre a sintetização dos dados, diminuindo a quantidade de pesos a serem aprendidos evitando possíveis sobreposições. Após a realização do *Max-pooling* foi adicionada mais uma camada 2d para a simplificação dos dados.

Adicionou-se uma camada *Flatting*, que transforma uma matriz em um array. Por final foi adicionada 2 camadas de *dense* com o objetivo de conectar todas as camadas e realizar todas as comparações entre elas. Utilizou-se 128 unidades de neurônios com a ativação *ReLu* na primeira camada de *dense*, onde determina os valores negativos ou positivos. Na segunda camada de *dense* utilizou-se 1 unidade de neurônio com ativação sigmóide (função de regressão logística).

Após todas as camadas configuradas é realizada a compilação geral do conjunto de camadas.

Utilizou-se também o algoritmo *Adan* para a otimização de aprendizado, desenvolvido para o treinamento de redes neurais.

Definiu-se após todos os processos de camadas as métricas a serem adotadas (acurácia e MSE).

Quadro 1 – Linguagens de programação, API e Bibliotecas utilizadas

Tipo	Nome	Versão e utilização
Linguagem de programação	Python	v.(3.7.12)

API	Kaggle	v.(1.5.12) API utilizado para efetuar o download do Dataset
Lib	OS	v.(3.7) Biblioteca nativa do Python que configura o ambiente que será executado

Lib	Zipfile	v.(3.7) Biblioteca nativa do Python para trabalhar com arquivos zip
Lib		n/cv2 v.(4.1.2.30) API para trabalhar com imagens
Lib	Matplotlib	v.(3.2.2) API para trabalhar com visualizações de gráficos estatísticos
Lib	Numpy	v.(1.19.5) Utilizada para realizar tratamentos de forma estatística sobre os dados
Lib	Keras	v.(2.7.0) Utilizada sobre o Tensorflow para aprendizado de máquina

Fonte: Elaborado pelos autores com informações extraídas diretamente do Kaggle(chest-xray-pneumonia).

Quadro 2 – Modelos e Camadas

Tipo	Nome	Utilização
Modelo	Sequential	Possui a capacidade de agrupar camadas de forma linear
Camada	Conv2D	Possibilita realizar a convolução (cálculo/análise sobre dois inputs/dados para gerar o resultado sendo o terceiro item).

Camada	MaxPooling2	Simplifica os dados da saída da camada anterior, onde é escolhido unidades de área para guardar as informações
Camada	D Flatten	Possibilita realizar o nivelamento dos dados de saída gerados pelas camadas anteriores e transformando-as para array.
Camada	Dense	Possibilita que os neurônios receba os dados/outputs das camadas anteriores, para assim a comparação das imagens serem melhores efetivas

Fonte: Elaborado pelos autores com informações extraídas diretamente do Kaggle(chest-xray-pneumonia).

2 FUNDAMENTAÇÃO TEÓRICA

Baseando-se nos dados coletados até o presente momento, este artigo propõe um breve relato sobre as tecnologias envolvidas para o desenvolvimento e aplicação do tema escolhido.

2.1 – *Machine Learning* (Aprendizado da máquina)

O *Machine Learning* ou aprendizado de máquina em tradução livre, é uma maneira de analisar dados de forma a orientar o computador a aprender de forma autônoma, onde é possível o aprimoramento de seu desempenho através de problemas específicos. Para o funcionamento do sistema é utilizado algoritmos complexos para a tomada de decisões e interpretações dos dados, permitindo a execução das tarefas automaticamente.

O *Machine Learning* atua juntamente com a Inteligência Artificial que por sua vez, busca a simulação do comportamento e das capacidades humanas, auxiliando nas tomadas de decisões, na detecção de anomalias, na interpretação visual dos dados, entre outras. O *Machine Learning* através da Inteligência Artificial, permite o aprendizado de algumas funções até então apenas realizadas pelo homem.

Podemos definir a inteligência como a capacidade de compreender e resolver problemas e conflitos e de adaptar-se a novas situações. Nesse contexto o autor afirma que:

“Aprendizado e inteligência estão intimamente relacionados um ao outro. Há geralmente a concordância de que um sistema capaz de aprender mereça ser chamado de inteligente; e, reciprocamente, de um sistema considerado como inteligente espera-se, geralmente, entre outras coisas, que seja capaz de aprender.

Aprendizado sempre tem a ver com o auto-aprimoramento do comportamento futuro, baseado em experiência passada”. (Gerhard Weiss, Learning in Multiagent Systems, p.259)

Nos problemas de aprendizado, as tarefas consistem em aprender a classificar as entradas conforme um conjunto finito ou infinito de classificações. Em geral, o sistema de aprendizado é composto por um conjunto de dados de treinamento, classificados manualmente. A partir disso, o sistema dedica-se a aprender através dos dados de treinamento, classificando-os. Aprender a classificar dados desconhecidos presume-se na relação entre os dados e as classificações. Desta forma, uma função f poderá ser criada se um conjunto de dados x pertencer à classificação y . Então: $f(x) = y$

Nos problemas de aprendizado na maior parte dos casos, utilizam-se mais de uma variável nos dados de entrada, aumentando a complexidade no mapeamento correto de uma função. Conforme sugere Coppin (2010), no método de aprendizado de máquina por hábito, o treinamento consiste em guardar cada fragmento de dado de treinamento e sua classificação. Dessa forma, um aprendiz por hábito apenas é capaz de classificar os dados conhecidos.

Há diversos métodos que podem ser utilizados no aprendizado de “conceitos”, de acordo com Coppin (2020):

“A tarefa do aprendiz de conceitos é examinar um conjunto de dados de treinamento positivos e negativos e usá-los para determinar uma hipótese que combine com todos os dados de treinamento e que, então, possa ser usada para classificar instâncias que não tenham sido observadas previamente.

O aprendizado de conceitos pode ser considerado uma busca em um espaço de busca que consiste em todas as hipóteses possíveis, onde o objetivo é a hipótese que mais se aproxima de uma representação do mapeamento correto”. (COPPIN, 2020, p.233)

2.2 Tecnologia na medicina

A imagiologia médica (exame de imagem) é uma especialidade médica que se baseia

no uso de tecnologias por imagem para recriar imagens fiéis do corpo humano, para definição, apoio e execução de diagnósticos e análises clínicas. Esta especialidade médica tem responsabilidade direta na comunicação médica, direcionada à investigação e aprendizado no processo de cuidados e evolução da saúde de forma geral.

O avanço das tecnologias envolvidas e utilizadas pela imagiologia médica tem evidenciado técnicas cada vez mais complexas e sofisticadas, indo além da simples visualização das estruturas de forma estática, possibilitando a visualização de funções dos tecidos atrelados a esta estrutura. Diante dos diversos tipos de equipamentos e maquinários de imagem, as modalidades de imagens capturadas são de forma analógica e digital.

Diante da grande diversidade de possibilidades de aquisição de imagem, um padrão médico se faz necessário. Para tanto, o padrão mundial adotado é o *Digital Imaging and Communications in Medicine* (DICOM). Este padrão define com rigor os formatos das imagens médicas, padronizando a forma de armazenamento e quais informações estão atreladas a esta imagem, além de estabelecer como se dará a comunicação entre os diversos tipos de aparelhos e máquinas envolvidos no envio e recepção dos dados.

As imagens médicas podem ser discriminadas por diversos parâmetros de qualidade, dos quais os mais relevantes para este estudo são a Resolução espacial e a Resolução de contraste.

- Resolução espacial: Está atrelada à nitidez, de forma a discriminar o quão juntos estão os pontos em uma imagem. Sendo que a resolução espacial normalmente está atrelada ao número de pixels por área de imagem
- Resolução de contraste: Está relacionada com a possibilidade de diferenciar pequenas variações de intensidade, atreladas a parâmetros mensuráveis, como atenuação de raios-x por exemplo.

As principais vantagens do *Machine Learning* na medicina estão diretamente ligadas à área de diagnósticos, pois esta induz a uma maior precisão na análise e maior rapidez na realização dos exames e otimiza a disponibilidade dos resultados.

O *Machine Learning* funciona a partir de um amplo e diversificado banco de dados contendo um acervo de sintomas de pacientes, de forma a estabelecer padrões para cada anomalia. Munido destas informações, o algoritmo discrimina e distingue um indivíduo possa vir a possuir uma determinada anomalia de acordo com os sintomas estudados.

Os principais benefícios da aplicação do *Machine Learning* na imagiologia médica são:

- Redução nos custos operacionais
- Maior desempenho em relação a produtividade de médicos e dos serviços de saúde;
- Assertividade na escolha de tratamentos efetivos
- Detecção e controle de doenças, impedindo ou retardando a sua progressão, tendo impacto direto na vida do paciente;
- Maior qualidade, acessibilidade, agilidade e efetividade para pacientes, médicos e organizações.

Para este estudo utiliza-se unicamente imagens digitais oriundas de equipamentos de Raio-X, voltadas ao diagnóstico de anomalias pulmonares.

2.2.1 Deep Learning

O *Deep Learning* ou Aprendizado Profundo em tradução livre, é uma sub-área de *Machine Learning*. Trata-se de Redes Neurais Artificiais (área que visa simular computacionalmente o cérebro enquanto máquina de aprendizado).

O *Deep Learning* é uma evolução técnica do *Machine Learning* que compreende um conjunto de algoritmos para realizar tentativas de modelar abstrações de alto nível de dados, com estruturas complexas e composto por várias transformações.

De acordo com Deng, Yu (2013, p.214 apud Valdati, Aline, 2020. p. 43.):

“Desta forma, a Deep Learning, ou aprendizado profundo, “refere-se a uma classe bastante ampla de técnicas e arquiteturas de aprendizado de máquina, com a diferenciação de usar múltiplas camadas de processamento de informações não lineares de natureza hierárquica”.

Segundo Rouhani (2019, apud Valdati Aline, 2020. P43.):

“Este tipo de técnica faz parte dos mais amplos métodos do Machine Learning baseado em representações de aprendizagem de dados. Podemos exemplificar com uma observação de imagem, onde pode ser representada de várias maneiras, uma delas por intensidade de pixels, identificando tom de cores com precisão e através do mesmo podemos imaginar o reconhecimento de expressão facial a partir de exemplos”.

Ainda conforme o mesmo autor Rouhani (2019, apud Valdati Aline, 2020. P43.):

“Técnicas de Deep Learning permitem que as redes neurais com várias camadas de processamento aprendam representações de dados com vários níveis de abstração.

Por ser um processamento pesado, a utilização de tais métodos otimizou desde o reconhecimento de fala, o reconhecimento visual de objetos, a detecção de objetos, até a descoberta de medicamentos e genômica”.

O objetivo do *Deep Learning* busca auxiliar os seres humanos em processos que os exigem, assim complementando atividades e passando a ser suportadas por uma inteligência artificial, buscando atender algoritmos eficientes como o supervisionado ou semi-supervisionado.

Os modelos do *Deep Learning* buscam aprender representações a partir de dados não rotulados em grande escala, algumas são inspiradas pelos avanços de neurociência e são baseados na interpretação do processamento de informações e padrões de comunicação de um sistema nervoso, como codificação neural que tenta definir um relacionamento entre o estímulo e as respostas neurais e a relação entre a atividade elétrica dos neurônios do cérebro.

Existem diversos modelos de aprendizagem profunda como redes neurais profundas, convolucionais (aprendizado a partir do erro) aplicados a campos de visão computacional, reconhecimento de fala automática ou áudio, processamento de linguagem natural e bioinformática.


2.2.2 Deep Learning aplicado à Medicina

Com base em estudos tecnológicos e dados coletados do *Computer Science Teachers Association* (CSTA) nos últimos anos, o *Deep Learning* tem ajudado todos os tipos de profissionais da área médica a descobrir novas oportunidades na área da saúde. A sua utilização na área fornece aos médicos uma análise mais precisa sobre doenças, apoiando decisões médicas mais assertivas.

O algoritmo Rede Neural Convolucional ou *Convolutional Neural Network* (CNN) analisa uma imagem médica através do *Deep Learning*, que recebe imagens, e a cada *layer* (camada) vai capturando recursos importantes para reduzir o número de parâmetros que devem ser calculados, assim aumentando a eficiência de sua análise. O CNN é capaz de analisar imagens 2D como Raio-X e imagens 3D como a ressonância magnética.

A figura 1 exibe o algoritmo CNN na prática, onde um raio-x de cabeça é inserido e ao passar por cada *layer* do CNN, é possível dizer se há um tumor no cérebro ou não.

Figura 1 - Fluxo algoritmo CNN



Fonte: Deep Learning in the Biomedical Applications: Recent and Future Status.

2017 2.3 Máquina x Homem (Vantagens da máquina)

Em uma tarefa de diagnóstico para detectar doenças através de imagens médicas, sabe-se que a utilização de *Deep Learning* pode auxiliar nas execuções das atividades, possibilitando que seja obtido economia de tempo.

De acordo com o estudo “A comparison of deep learning performance Against health-care professionals in detecting diseases from medical” (em tradução livre “Uma comparação do desempenho de aprendizagem profunda com profissionais de saúde na detecção de doenças por imagens médicas: uma revisão sistemática e meta-análise”) publicado na revista científica The Lancet, comparando o desempenho de modelos de diagnóstico de *Deep Learning* com profissionais de saúde utilizando como base imagens médicas, foi identificado que os estudos forneceram dados suficientes para construir tabelas de contingência, permitindo realizar conclusões dos testes.

A comparação de desempenho entre Homem x Máquina neste estudo resultou em uma precisão de 87% para os modelos de *Deep Learning* e 86% para os profissionais da saúde. Diante destes resultados é possível concluir que o desempenho dos modelos de *Deep Learning* é equivalente aos dos profissionais de saúde, onde os resultados podem ajudar na

identificação de doenças de forma antecipada e efetuar o tratamento a tempo, porém é necessário um banco de dados consistente ao longo dos anos para que os resultados sejam mais assertivos.

Os algoritmos de *Deep Learning* simplificam a análise de dados complexos, portanto, as anormalidades são determinadas e priorizadas com mais precisão. São inúmeras as vantagens que o uso do *Deep Learning* trás para a área da saúde. A utilização desta tecnologia proporciona que a máquina apresente respostas precisas e agilidade na geração de diagnósticos, diminuição de erros por meio da auditoria de prescrições e resultados de diagnóstico, redução de custos e carga de trabalho administrativo, etc.

De acordo com os autores Steffen E. Petersen, Musa Abdulkareem, Tim Leiner

(201

9. p.

1):

Graças às oportunidades disruptivas, a inteligência artificial através do Deep Learning vem oferecendo uma nova forma de como fornecemos imagens na área da saúde. No entanto, muitos desafios permanecem e precisam ser enfrentados de forma proativa para manter os pacientes e o público abertos ao desenvolvimento e introdução de soluções de IA. O potencial é empolgante para tornar os sistemas de saúde melhores em termos de qualidade, igualdade e relação custo-benefício.

3 ESTUDO DE CASO


O estudo de caso elaborado tem como objetivo mostrar na prática os benefícios que o *Deep Learning* pode prover ao médico, classificando imagens de raio-x como saudável ou não.

Para o desenvolvimento do estudo foi utilizado *Dataset* de imagens de raio-x, linguagem de programação python, api's de aprendizado de máquina, plataforma *Google Colab* como base para execução dos algoritmos e *Jupyter Notebook* para treinos de maiores durações em busca de melhorar a acurácia.

3.1 Recursos utilizados

Para a realização do estudo de caso, utilizamos como método a classificação de aprendizado de máquina para prever qual categoria de imagem a classe pertence. Foram utilizados três tipos de rótulos de imagens (Treinamento, teste e validação) para nortear o algoritmo, onde os dados de validação são utilizados como critério de parada, evitando o *overfitting*. As imagens utilizadas são binárias possuindo classificação de “Regular sem anomalia” e “Irregular com anomalia”, as imagens não possuem dimensionamento fixo, portanto umas podem ser maiores ou menores que as outras. A classificação é uma técnica de aprendizado de máquina supervisionado, onde permite o treinamento do modelo com a utilização do *Dataset* da plataforma *Kaggle* com o título “*Chest X-Ray Images (Pneumonia)*”, contendo um tamanho de 1.24GB. O modelo de dados inclui recursos e valores conhecidos de rótulo para que o modelo aprenda a ajustar as combinações de recursos ao rótulo. Em seguida, após a conclusão do treinamento, a classificação é obtida. Nesse caso, imagens “Regular sem anomalia” e “Irregular com anomalia”, conforme figura 2.

Figura 2 - Classificação dos tipos de imagens do *Dataset*. (a) Regular sem anomalia e (b) Irregular com anomalia



(a) (b)

Fonte: Dados do Kaggle(chest-xray-pneumonia)

As imagens de treino são utilizadas para treinar o algoritmo quanto maior a quantidade

de treino, melhor o resultado, conforme tabela 1.

Tabela 1 – Quantidade de Imagens de Treino

Tipo	Quantidade
Regular sem anomalia	1341
Irregular com anomalia	3875
Total de amostras (Kaggle)	5216

Fonte: elaborado pelos autores com informações extraídas do *dados* Kaggle(chest-xray-pneumonia).

As imagens de validação são utilizadas para validar o treinamento, ou seja, executada junto ao treino para o algoritmo conseguir validar e classificar as imagens de testes, conforme tabela 2.

Tabela 2 – Quantidade de imagens de validação

Tipo	Quantidade
Regular sem anomalia	8
Irregular com anomalia	8
Total	16

Fonte: elaborado pelos autores com informações extraídas do *dados* Kaggle(chest-xray-pneumonia).

As imagens de teste são utilizadas para testar o algoritmo, que serve para definir se o treinamento do algoritmo foi bem-sucedido, conforme tabela 3.

Tabela 3 – Quantidade de imagens de teste

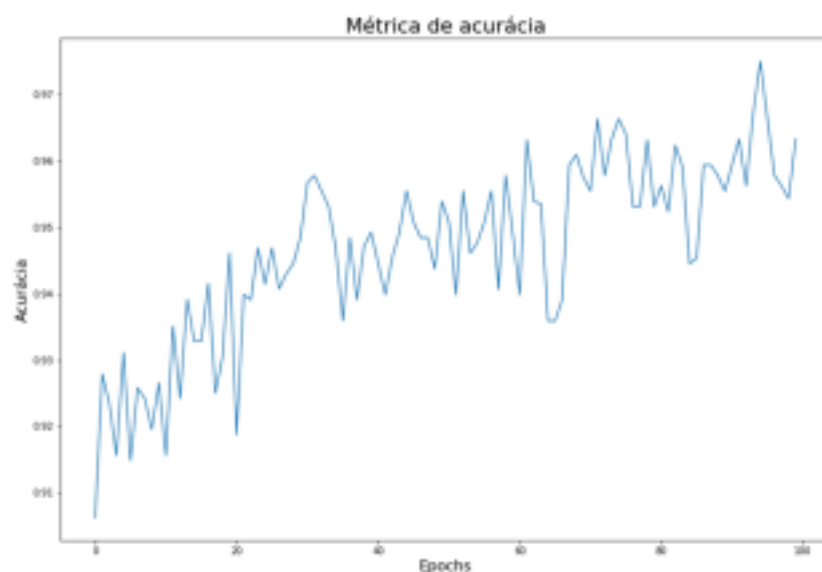
Tipo	Quantidade
Regular sem anomalia	234
Irregular com anomalia	390
Total	624

Fonte: elaborado pelos autores com informações extraídas do *dados* Kaggle(chest-xray-pneumonia).

3.2 Resultados com métricas

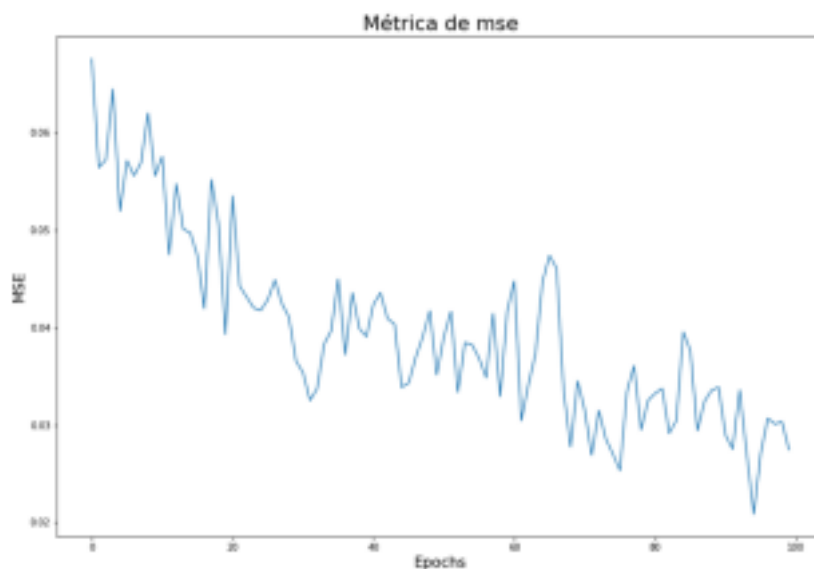
Utilizou-se como métrica de avaliação do modelo a acurácia e *Mean Squared Error* (MSE). A acurácia avaliou o percentual de acertos (número de acertos (positivos) dividido pela quantidade total da amostra) e o MSE calculou o percentual de erros, conforme figuras 3 e 4.

Figura 3 - Métrica de acurácia



Fonte: Elaborado pelos autores com informações extraídas após processamento de modelo

sequencial. Figura 4 - Métrica de MSE (Mean Squared Error)




Fonte: Elaborado pelos autores com informações extraídas após processamento de modelo sequencial.


3.3 Classificação das imagens

O algoritmo realiza a classificação das imagens e ao final da execução nos responde se a imagem que foi utilizada como input corresponde a um Raio-X com anomalia ou sem. Na tabela a seguir, temos exemplos de como funciona a classificação.

Figura 5 - Classificação das imagens a partir do algoritmo (a,c) Raio-x com anomalia (b,d)
Raio-x sem anomalia



(a) (b)



(c) (d)

Fonte: Dados do Kaggle(chest-xray-pneumonia)

3.4 Resultado final do estudo de caso

Com os dados preparados para as execuções de treinamentos, é perceptível que o

aprendizado de máquina consegue melhorar a classificação de imagem, se tornando um auxílio benéfico às atividades de análise sobre imagens de raio-x.

Pode-se concluir a partir dos resultados que, o uso de inteligência artificial tem se tornado cada vez mais presente nas atividades da área da saúde, onde foi demonstrado ao leitor um experimento utilizando a tecnologia de Deep Learning aplicada a medicina, realizando classificações de imagens de raio-x para constatação de anomalias pulmonares.

Salienta-se ainda, que quanto maior a quantidade de dados de treinamento, melhor será o resultado proporcionado pela máquina.

4 CONSIDERAÇÕES FINAIS

Neste artigo, é apresentado como o *Deep Learning* pode auxiliar no diagnóstico e análise de doenças pulmonares através do raio-x, mostrando o quanto a tecnologia pode melhorar a acurácia de diagnósticos médicos realizados por algoritmos.

Através de estudos bibliográficos oriundos de metodologias de pesquisa, foi possível melhorar a compreensão do assunto, possibilitando a realização de um estudo de caso utilizando algoritmos para treino, validação e teste de imagens, tendo como resultado a classificação de doenças pulmonares (“Regular sem anomalia” e “Irregular com anomalia”).

Os resultados obtidos através de um estudo de caso, apontou a tendência do uso de tecnologias como o Deep Learning como uma possibilidade de melhoria para a acurácia de diagnósticos médicos, permitindo que as organizações e médicos possam ter maior desempenho em relação a produtividade nos serviços de saúde, além de apontar para possíveis reduções de custos operacionais e maior qualidade e acessibilidade para pacientes, médicos e organizações. Com isso, a tecnologia de *Deep Learning* pode abranger outros tipos de diagnósticos por imagens num futuro próximo, além de poder ser utilizada na fomentação de banco de dados para pesquisas futuras de pesquisadores, assegurando o crescimento da tecnologia aplicada de forma consistente.

REFERÊNCIAS

Andrew Fogg; **A History of Machine Learning and Deep Learning**, 2018. Disponível em: <https://www.import.io/post/history-of-deep-learning/>. Acesso em 23 de maio de 2021.

Aysegul Takimoglu; **11 Deep Learning Use Cases / Applications in Healthcare in 2021**. <https://research.aimultiple.com/deep-learning-in-healthcare/> Acesso em: Setembro, 2021.

Brigiane, M, S; Marcos V, **Inteligência Artificial, Aprendizado De Máquina**, Santa Catarina, Vale do Itajaí/Maio. 2012.

CHAGAS, Edgar Thiago De Oliveira. **Deep Learning e suas aplicações na atualidade**. Revista Científica Multidisciplinar Núcleo do Conhecimento. Ano 04, Ed. 05, Vol. 04, pp. 05-26 Maio de 2019. ISSN: 2448-0959

COPPIN, Ben. **Inteligência artificial**. Rio de Janeiro: LTC, 2010.

Daniele Ravi et al; **Deep Learning for Health Informatics**.

https://www.researchgate.net/publication/312118124_Deep_Learning_for_Health_Informatics. Acesso em: 25 de Julho, 2021.

Kaggle. **chest-xray-pneumonia**. Disponível em:

<https://www.kaggle.com/paultimothymooney/chest-xray-pneumonia>. Acesso em: 01 nov. 2021

Deep_Learning_Applications_in_Medical_Image_Analysis. *Disponível em:*

https://www.researchgate.net/publication/322142760_Deep_Learning_Applications_in_Medical_Image_Analysis. *Acesso em: 01 dez. 2021.*

DICOM. Digital Imaging and Communication in Medicine. Disponível em:

<http://dicom.nema.org/>. Acesso em: 01 dez. 2021.

Diversos Autores, **Introduction to Machine Learning The Wikipedia Guide**. Disponível em:

<http://www.datascienceassn.org/sites/default/files/Introduction%20to%20Machine%20Learning.pdf>. Acesso em: 21 de Maio de 2021.

Fabricio, M. A. Behrens, F. B. D. (2016). **Monitoramento de Equipamentos Elétricos para Manutenção Preditiva utilizando IoT**. In Brazilian Technology Symposium, São Paulo, Brasil.

FERNANDES, Anita Maria da Rocha. **Inteligência artificial: noções gerais**. Florianópolis: Visual Books, 2003.

Galvão, Paulo. **Tecnologia e medicina: imagens médicas e a relação médico-paciente**. Revista Bioética, v. 8, n. 1, p. 127-136, 2000. Disponível em https://revistabioetica.cfm.org.br/index.php/revista_bioetica/issue/view/19. Acesso em: Maio, 2021.

GUSMÃO JUNIOR, Marcelo Bezerra. **Aplicando métricas de avaliação não-supervisionadas para imagens segmentadas**. 2020. 44 f. TCC (Graduação) - Curso de Ciências da Computação, Universidade Estadual da Paraíba, Campo Grande, 2020. Disponível em: <http://dspace.bc.uepb.edu.br/jspui/bitstream/123456789/22052/1/PDF%20-%20Marcelo%20Bezerra%20Gusm%C3%A3o%20J%C3%BAnior.pdf>. Acesso em: 01 dez. 2021.

Imagiologia. Disponível em: https://pt.wikipedia.org/wiki/Imagiologia_m%C3%A9dica. Acesso em: 01 dez. 2021.

Justin Ker et al; **Deep Learning Applications in Medical Image Analysis**.

https://www.researchgate.net/publication/322142760_Deep_Learning_Applications_in_Medical_Image_Analysis Acesso em: Julho, 2021.

Justin Ker et al; **Deep Learning Applications in Medical Image Analysis.**

<https://ieeexplore.ieee.org/document/8241753>. Acesso em: Julho, 2021.

Leibowitz David. AI Now Diagnoses Disease Better Than Your Doctor, Study Finds. **TowardsDataScience**, 2020. Disponível em:

<https://towardsdatascience.com/ai-diagnoses-disease-better-than-your-doctor-study-finds-a5cc0ffbf32>. Acesso em: 07 de maio de 2021.

Marcel, K. S et al. **Inteligência artificial, aprendizado de máquina, diagnóstico auxiliado por computador e radiômica**: avanços da imagem rumo à medicina de precisão, São Paulo, vol.52 no.6 São Paulo Nov./Dec. 2019.

MENDES, Yana. Uso de Redes Complexas para Classificação de Doenças Pulmonares Intersticiais em Imagens de Tomografia Computadorizada. In: SIMPÓSIO BRASILEIRO DE COMPUTAÇÃO APLICADA À SAÚDE (SBCAS), 20., 2020, Porto Alegre. Sociedade Brasileira de Computação, 2020. v. 1, p. 1-12. Disponível em: <https://sol.sbc.org.br/index.php/sbcas/article/view/11528/11391>. Acesso em: 01 dez. 2021.

Naveen Joshi; **Top 5 applications of Deep Learning in healthcare**; Disponível em: <https://www.allerin.com/blog/top-5-applications-of-deep-learning-in-healthcare/>. Acesso em 23 de maio de 2021.

Ryan Zemouri, Nouredine Zerhouni, Daniel Racocanu; **Deep Learning in the Biomedical Applications: Recent and Future Status.**

https://www.researchgate.net/publication/332391435_Deep_Learning_in_the_Biomedical_Applications_Recent_and_Future_Status. Acesso em: Setembro, 2021.

RUSSEL, Stuart e NOVING, Peter. **Inteligência artificial**, São Paulo, Campus, 2004.

SILVA, Brigiane Machado da. **INTELIGÊNCIA ARTIFICIAL, APRENDIZADO DE MÁQUINA**. 2012. 10 f. Universidade do Estado de Santa Catarina, Santa Catarina, 2012.

Disponível em:
http://www.ceavi.udesc.br/arquivos/id_submenu/387/brigiane_machado_da_silva___marcos_vanderlinde.pdf. Acesso em: 01 dez. 2021.

Steffen E. Petersen, Musa Abdulkareem, Tim Leiner³; **Artificial Intelligence Will Transform Cardiac Imaging—Opportunities and Challenges**.
<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC6746883/> Acesso em: Setembro, 2021.

VALDATI, Aline de Brittos. **INTELIGÊNCIA ARTIFICIAL**. Curitiba: Contentus, 2020

WEISS, Gerhard. **Multiagent Systems – A Modern Approach to Distributed Artificial Intelligence**. Eua: Mit Press, 1999. Disponível em:
<https://www.emse.fr/~beaune/maml/sen-weiss-MAL99.pdf>. Acesso em: 01 dez. 2021.

Xiaoxuan Liu et al; **A comparison of deep learning performance against health-care professionals in detecting diseases from medical imaging: a systematic review and meta-analysis**.
<https://www.thelancet.com/action/showPdf?pii=S2589-7500%2819%2930123-2>. Acesso em: Setembro, 2021.

GESSER, Carlos Eduardo; **O que é DICOM e quais são os seus benefícios**; <https://www.pixeon.com/blog/o-que-e-dicom-e-quais-sao-seus-beneficios/>. Acesso em: 19 dez, 2021

J. Ker, L. Wang, J. Rao and T. Lim, **Deep Learning Applications in Medical Image Analysis**; <https://ieeexplore.ieee.org/document/8241753>. Acesso em: 19 dez, 2021 HUNTER John; **Matplotlib**; <https://matplotlib.org/>; Acesso em: 19 dez, 2021 Harris, C.R., Millman, K.J., van der Walt, S.J. et al; **Array programming with NumP**; <https://numpy.org/>; Acesso em: 19 dez, 2021

Keras, <https://keras.io/>; Acesso em: 19 dez, 2021

Opencv, <https://opencv.org/>; Acesso em: 19 dez, 2021

Python Software Foundation; **Zipfile**, <https://docs.python.org/3/library/zipfile.html>; Acesso em: 19 dez, 2021

Python Software Foundation; **OS**, <https://docs.python.org/3/library/os.html>; Acesso em: 19 dez, 2021

Computer Science Teachers Association; **CSTA**, <https://www.csteachers.org/>; Acesso em: 19 dez, 2021